

Literaturbesprechungen in historischen Zeitungen

Korpusbildung und Analyse diachroner Entwicklungen mit LLMs und NLP-Methoden

Johanna Mauermann
JGU Mainz/Hochschule Mainz
jmauerma@students.uni-mainz.de
Erstgutacher:
Prof. Dr. Gerhard Lauer
Zweitgutachterin:
Assist. Prof. Sarah Oberbichler



Einleitung

Forschungslücke & Motivation

Historische Literaturbesprechungen in Zeitungen bieten ein Erkenntnispotenzial im Hinblick darauf, welche Literatur - jenseits heutiger Kanones - in der Vergangenheit für eine breite Öffentlichkeit von Interesse war. Bisher wurden Rezensionen in der Forschung jedoch kaum quantitativ untersucht, u. a. wegen der herausfordernden Auffindung der Texte innerhalb von Zeitungen. Klassische NLP-Methoden stoßen hier schnell an Grenzen, v. a. wenn keine manuell erstellten Trainingsdaten vorhanden sind. Daher bieten LLMs durch ihr kontextuelles Sprachverständnis einen vielversprechenden, skalierbaren Ansatz zur Erschließung historischer Rezensionen.

Forschungsfrage der Masterarbeit

Wie entwickeln sich Literaturrezensionen in der Kölnischen Zeitung im Verlauf des 19. Jahrhunderts?
Inwieweit können LLMs Korpusaufbau, -anreicherung und das Auffinden systematischer Muster unterstützen?

Datenbasis

- Kölnische Zeitung (1814–1900), eine der bedeutendsten überregionalen deutschen Tageszeitungen, mit Feuilleton-Rubrik ab 1838
- Zugang über API der Deutschen Digitalen Bibliothek (OCR-Texte)
- Sample: 1.740 Zeitungsseiten (je 20 zufällige Seiten/Jahr), daraus 633 manuell verifizierte Rezensionen


Methodik

Schritt 1 - Korpusaufbau (Rezensionsextraktion)

- Keyword-Vorauswahl (z. B. 'Literatur', 'Schriftsteller') & Kontextfenster um Keywords zur Reduktion der Datenmenge
- Promptbasierte Rezensionsextraktion via **GPT OSS 120B & Qwen3 235B** (Zero-Shot, XML-Output)
- Modell liefert Extraktionstext (<review>) + Begründung (<justification>) + Unsicherheitsmarkierung (<human_verification_needed>)
- Evaluation: Ground Truth + angepasstes bestehendes Evaluationsframework (Oberbichler et al., 2025)

Schritt 2 - Korpusanreicherung mit Metadaten & Sentiment

- Promptbasierte Extraktion und Klassifikation (strukturiert im XML-Format) für Kategorien wie: Titel, Autor:in, Geschlecht, Verlag, Genre, Übersetzungsstatus, 6 Bewertungs-Dimensionen



- Evaluation via Ground Truth: 20 manuell annotierte Rezensionen; Übereinstimmung Mensch–Modell: GPT 81,8 %, Qwen 83 %
- Close Reading von Modelloutputs zur ergänzenden Validierung
- Human-in-the-Loop: Alle 185 von mind. einem Modell als unsicher markierten Fälle wurden manuell korrigiert

Ergebnisse & Diskussion


Inhaltliche Befunde der Analyse (Auswahl)

- Zeitliche Entwicklung: Rezensionen nehmen im Datensatz ab den 1840er-Jahren deutlich zu; Feuilleton-Rubrik (ab 1838) womöglich als Katalysator
- Bewertungstendenzen: Positive Bewertungen dominieren durchgehend, somit scheint funktional der Empfehlungsaspekt wichtig für die Literaturkritik in der Zeitung zu sein
- Übersetzungen: Anteil sinkt von > 30 % (1830er) auf < 10 % (ab 1870er) → Deutsch als Literatursprache gewinnt an Gewicht; häufigste Ausgangssprachen für Übersetzungen: Französisch, Englisch
- Geschlechterdisparität: Nur 35 von 633 Rezensionen behandeln Werke von Frauen (< 10 % in allen Jahrzehnten); darunter überwiegend belletristische Werke

- Genre-Zusammensetzung: Der Roman wird anteilmäßig häufiger gegen Ende des Analysezeitraums besprochen; dagegen leicht rückläufige Tendenzen bei Drama und Lyrik

Biases & Limitationen

- In der Evaluation zeigen sich modellspezifische Fehlerprofile, die bei einer Analyse mitbedacht werden müssen; z. B. bei der Erkennung von Rezensionen viele False Negatives bei GPT und viele False Positives bei Qwen
- Nur ausschnittshafte Datenset → insbesondere diachrone Entwicklungen mit Vorsicht zu interpretieren
- Opakheit und hoher Ressourcenverbrauch von LLMs als Methode



Beispielhafte Auswertungen der Daten

Fazit & Ausblick

Methodische Erkenntnisse

- Der entwickelte mehrschrittige LLM-Workflow (Keyword-Selektion → Extraktion → Anreicherung mit Sentiment und Metadaten) erscheint grundsätzlich anhand historischer Zeitungen einsetzbar und bietet Potential für eine Skalierung.
- Dabei sollte berücksichtigt werden, dass bei der komplexen historischen Datengrundlage und teilweise interpretativen Aufgaben keine perfekte Übereinstimmung zwischen manueller Annotation und Modelloutput zu erwarten ist.

- Ein kombiniert quantitativ-qualitativer Ansatz ist zielführend bei der Evaluation, um modellspezifische Fehler zu erkennen.
- Der erprobte Human-in-the-Loop-Mechanismus erweist sich dabei als effektiv für eine gezielte manuelle Überprüfung schwieriger und ambiger Fälle.

Inhaltliche Erkenntnisse

- Die Analyseergebnisse können einige Tendenzen aufzeigen, wie z. B. die Dominanz positiver Wertungen, eine Unterrepräsentation der Werke von Frauen bei den Literaturbesprechungen, und eine relative Abnahme von Übersetzungen im Laufe des 19. Jahrhunderts.

- Aufgrund der nur ausschnittshafte Datenbasis sind die Ergebnisse primär als Hypothesen zu verstehen, die anhand einer breiteren Datenbasis in künftiger Forschung überprüft werden sollten.

Ausblick

- Neben einer Ausweitung des Korpus, erscheinen LLM-gestützte OCR-Korrektur als Preprocessing, Few-Shot-Prompting, Entitätsnormalisierung und Linked Data für Kategorien wie Werktitel oder Autor:in, sowie auch der Vergleich der Rezensionen mehrerer Zeitungen vielversprechend.

Literatur & Quellen

Literatur

- Oberbichler, S., Mauermann, J., Tran, T., & González-Gallardo, C. (2025). Studying Model Design Biases in LLMs for Multilingual Historical Newspaper Extraction; The Messina Earthquake Case Study. Linking Theory and Practice of Digital Libraries, Lecture Notes in Computer Science, 16097, 263–286. https://doi.org/10.1007/978-3-032-05409-8_16

GitHub-Repository der Arbeit

- https://github.com/johannamauermann/Masterarbeit_Literaturbesprechungen; zuletzt aufgerufen: 03.05.2026.